

Contents

When Should LLM Training Change the Spectrum?	2
Credit Assignment Determines the Spectral-Frame Geometry of Gradients —统一文档	2
0. 核心主张	2
1. 背景	2
1.1 三种范式	2
1.2 已有工作与空缺	2
1.3 Weights 分析 vs Gradients 分析	3
Part I —理论	3
2. 统一梯度形式	3
2.1 所有 objective 的梯度都是 $\sum_t \delta_t x_t^\top$	3
2.2 投到权重奇异基	3
3. Spectral-Frame 分解	3
4. RLVR 的 covariance 结构	4
5. SNR 理论：幅值混合了信号与尺度	5
6. Part I 实验协议	6
6.1 Setup (固定)	6
6.2 指标	6
6.3 假设与预测	6
6.4 干预协议 (Phase 2)	7
Part II —优化方法	7
M1. Spectral-SNR Descent (SSD)	7
M2. Adaptive Spectrum-Frame Learning Rates	7
M3. Contribution-Aware Spectral Regularizer	8
M4. Layer-Wise Optimizer Routing	8
M5. Subspace-Locked Optimizer States	8
M6. SNR-Guided Credit Densification	8
M7. SNR-Aware Rank Allocation for LoRA	8
推荐配置	8
6b. Part II 理论	8
6b.1 M1 的最优性	8
6b.2 M2 的谱漂移控制	9
6b.3 M3 的遗忘界	9
7.1 通用设置	9
7.2 实验清单	10
7.3 全文图表清单	10
7.4 算力估计 (3B 模型)	10
7.5 依赖关系	11
Part III —执行	11
时间线	11
工程	11
待定	11
附：理论的诚实边界	11

When Should LLM Training Change the Spectrum?

Credit Assignment Determines the Spectral-Frame Geometry of Gradients —统一文档

结构: - **Part I** 分析: 理论 (含证明) + 实验协议 - **Part II** 方法: 由 Part I 的发现触发的优化方法 - **Part III** 实验与时间线

0. 核心主张

给定 pretrained 权重 $W_0 \in \mathbb{R}^{m \times n}$, post-training objective 产生梯度 G_t , optimizer 给出 update H_t , $W_{t+1} = W_t + H_t$, $W_t = U_t \Sigma_t V_t^\top$.

实验判定注记 **2026-09-08** —Phase 1 已在 Qwen3.5-0.8B 六格与 Llama-3.2-3B/1B 家族轴上完成。标注约定: 删除线 = 被实验推翻; 【判定】= 实验结果注记。总览:**H2** 强成立;**H1/H4** 方向成立、幅度温和;**H3** 即 **H-RLVR** 被干净证伪——frame-dominance 的机制归因唯一化到 §5 的 SNR/方差通道, 即 § 附”独立性” 预案所述主线。计划外发现: 线性注意力矩阵的梯度谱对角富集显著低于随机基线, 约 0.65, 而 MLP 约 1.0, 三范式一致, 属架构效应; Muon 的 H 谱富集在 RLVR 下消失,H/G 约 1.0, 稠密范式约 1.1。H5/H6 因果干预与 E1-E4 在途, 由作者 B 执行。

三个可证伪主张:

- **C1 (Objective-determined)**: spectral-vs-frame 倾向在 raw gradient G_t 中已存在, optimizer 只是调制。【判定 强支持: 三范式 $\times$ AdamW/Muon 共三对,G 侧谱几何差异均 $<7\%$; Muon 对 H 的谱调制在稠密范式约 $+11\%$ 、在 RLVR 消失】
- **C2 (Credit-assignment mechanism)**: RLVR 的 frame-dominance 来自 sequence-level 标量 credit 与 score-function 零均值的组合, 可写成 covariance 并给出机制。【判定 机制部分被证伪:covariance 形式 (Prop.5) 数学成立, 但 per-mode reward 相关在 与 frame 方向完全对称 ($8\times$ 统计力, 中位数 0.1314 vs 0.1308, 匹配零假设 0.1305)——序列级破缺不存在,frame-dominance 改由 C3 的 SNR/方差通道解释, 详见 §4 判定】
- **C3 (SNR, not magnitude)**: gradient 各 singular mode 的幅值混合了”与 reward 的相关性”和”该 mode 统计量的方差”, 后者与 signal 无关; 按 SNR 选方向优于按幅值。【判定 弱形式成立:Spearman($|C|$,SNR) 排序 SFT>OPD>RLVR 在 Qwen-0.8B(0.880/0.874/0.848) 与 Llama-3B(0.863/0.809/0.785) 两个架构上一致, 标准注意力上差距更大; “RLVR 低相关” 的强形式未出现; 决定性因果检验为 H6 干预 (在途)。本主张现为全文机制主线】

1. 背景

1.1 三种范式

	SFT	OPD	RLVR
数据	外部固定	student 采样	student 采样
监督	每 token 一个 target	每 token 一个 teacher 分布	每序列一个标量
密度	稠密	稠密	极稀疏
on-policy	否	是	是

OPD 与 SFT 同为稠密但 on-policy; 与 RLVR 同为 on-policy 但稠密。它分离了” on-policy 采样” 和” 信号密度” 两个因素。

1.2 已有工作与空缺

- **ISO (RLVR)**: $\sigma(W_T) \approx \sigma(W_0)$, 固定谱只训 U, V 即可。未解释原因。
- **OPD geometry** 两篇: ΔW 避开主子空间、numerically full-rank 但 spectrally concentrated、FFN-heavy、早期 subspace locking。全是 checkpoint 级。
- **Muon / Pion / Spectra**: Muon 全谱拉平; Pion 按幅值保头压尾并报告 RLVR 下 Muon 放大 tail noise; 隐含” 大奇异值 = 信号”。

- **NaNA** (ICML 2026): MLP 权重 SVD 的 rank-1 项为 Detector-Effector Unit, 贡献 $c_i = (\sigma_i v_i^\top x)(t^* u_i)$; top-20 恢复 97-99%。提供 mode 的功能标签。

空缺: 三范式从未在同一 checkpoint / 数据 / budget 下逐步对比; G_t 与 H_t 从未分开看; 无人解释 PG 对角分量为何小; “幅值 = 信号”未被检验。

1.3 Weights 分析 vs Gradients 分析

Weights 分析看 $W_0 \rightarrow W_T$: 累积量抹掉过程, 分不清 objective 与 optimizer 效应, 分不清“无信号”与“信号被噪声平均”。Gradients 分析看每步 G_t, H_t : 能分离 objective 性质、optimizer 效应、noise 结构、时间动态。本文三个主张全在 gradients 侧; weights 侧累积量作 sanity check。

Part I —理论

2. 统一梯度形式

2.1 所有 objective 的梯度都是 $\sum_t \delta_t x_t^\top$

对线性层 $y_t = Wx_t$, 任意 loss:

$$G = \sum_t \delta_t x_t^\top, \quad \delta_t := \partial \mathcal{L} / \partial y_t$$

objective 只通过 δ_t 进入。记 $g_t^{(\tau)} := \partial \log \pi(y_\tau | y_{<\tau}, x) / \partial y_t$ ($\tau \geq t$ 时非零)。

Objective	δ_t	credit 结构
SFT	$-\sum_{\tau \geq t} g_t^{(\tau)}$	每位置 credit = 1, target 固定
OPD (reverse KL)	$\sum_{\tau \geq t} [w_\tau g_t^{(\tau)} + \partial_{y_t} \text{KL}_\tau],$ $w_\tau = \log \pi_s(y_\tau) - \log \pi_t(y_\tau)$	每位置稠密、有符号
RLVR (GRPO)	$A \sum_{\tau \geq t} g_t^{(\tau)}$	整条序列一个标量

统一:

$$G = \mathbb{E} \left[\sum_t \sum_{\tau \geq t} c_\tau g_t^{(\tau)} x_t^\top \right] + (\text{OPD 直接项})$$

三范式唯一结构差别是 credit 向量 c : SFT 常数 1, OPD 稠密 teacher 信号, RLVR $c_\tau \equiv A$ 。“训练范式”从离散变量变为“credit 的密度与方差”这个连续变量。

2.2 投到权重奇异基

$$a_{i,t} := v_i^\top x_t, \quad e_{i,t} := u_i^\top \delta_t, \quad C := U^\top G V, \quad C_{ij} = \sum_t e_{i,t} a_{j,t}$$

对角 C_{ii} : 同一 mode 的 detector 激活与 effector 误差的相关 (改 gain)。非对角 C_{ij} : 把输入模式 v_j 路由到输出方向 u_i 的压力 (改 routing)。

3. Spectral-Frame 分解

Proposition 1 (一阶谱动力学)。设 $W = U \Sigma V^\top$ 奇异值互异, update $H, C = U^\top H V$ 。则

$$\dot{\sigma}_i = C_{ii}, \quad \dot{u}_i = \sum_{j \neq i} \frac{\sigma_i C_{ji} + \sigma_j C_{ij}}{\sigma_i^2 - \sigma_j^2} u_j, \quad \dot{v}_i = \sum_{j \neq i} \frac{\sigma_i C_{ij} + \sigma_j C_{ji}}{\sigma_i^2 - \sigma_j^2} v_j$$

证明. 由 $Wv_i = \sigma_i u_i$ 和 $W^\top u_i = \sigma_i v_i$ 对 $W \rightarrow W + \epsilon H$ 微分:

$$Hv_i + W\dot{v}_i = \dot{\sigma}_i u_i + \sigma_i \dot{u}_i, \quad H^\top u_i + W^\top \dot{u}_i = \dot{\sigma}_i v_i + \sigma_i \dot{v}_i.$$

第一式左乘 $u_i^\top$: $C_{ii} + \sigma_i v_i^\top \dot{v}_i = \dot{\sigma}_i + \sigma_i u_i^\top \dot{u}_i$. 单位范数给 $u_i^\top \dot{u}_i = v_i^\top \dot{v}_i = 0$, 故 $\dot{\sigma}_i = C_{ii}$. 第一式左乘 $u_j^\top$ ($j \neq i$), 记 $a = u_j^\top \dot{u}_i$, $b = v_j^\top \dot{v}_i$: $C_{ji} + \sigma_j b = \sigma_i a$. 第二式左乘 $v_j^\top$: $C_{ij} + \sigma_j a = \sigma_i b$. 联立解得

$$a = \frac{\sigma_i C_{ji} + \sigma_j C_{ij}}{\sigma_i^2 - \sigma_j^2}, \quad b = \frac{\sigma_i C_{ij} + \sigma_j C_{ji}}{\sigma_i^2 - \sigma_j^2}. \quad \blacksquare$$

推论 1.1. Spectral motion 能量 $= \|\text{diag } C\|^2$; frame motion 由非对角驱动, 被 $1/(\sigma_i^2 - \sigma_j^2)$ 放大. 定义

$$R_{\text{spectrum}}(G) := \frac{\|\text{diag}(U^\top G V)\|_F^2}{\|G\|_F^2}$$

它是 objective 施加的压力的分解; 实际旋转量还取决于谱间隙, 尾部近简并 mode 的旋转被放大. 这解释 OPD 观察到的 “numerically full-rank”: 即使 C 集中, 尾部近简并使旋转扩散.

Proposition 2 (spectrum-only update 的表达力). 若 $H_\Sigma = U \text{diag}(C) V^\top$, 则对任意 x

$$\Delta(Wx) = \sum_i C_{ii} (v_i^\top x) u_i.$$

证明. $H_\Sigma x = \sum_i C_{ii} u_i (v_i^\top x)$. $\blacksquare$

输出变化只沿已有 effector 方向、以已有 detector 激活为系数. Spectrum-only update 不能建立新的输入 $\rightarrow$ 输出关联, 所在参数子空间 r 维 (vs mn).

推论 2.1 (可检验). 需要新关联的任务在 spectrum-only 下必然失败; 只需重新加权已有关联的任务可以成功.

Proposition 3 (Optimizer 等变性). Muon 的 update $H = \text{polar}(G) = G(G^\top G)^{-1/2}$ 满足: 对任意正交 U', V' , $\text{polar}(U'^\top G V') = U'^\top \text{polar}(G) V'$. 因此

$$R_{\text{spectrum}}(H_{\text{Muon}}) = R_{\text{spectrum}}(\text{polar}(C)), \quad C = U^\top G V,$$

只依赖 G 相对 W 的对齐结构. Adam 的逐元素归一化不满足此性质, $R_{\text{spectrum}}(H_{\text{Adam}})$ 依赖坐标基.

证明. $(U'^\top G V')^\top (U'^\top G V') = V'^\top G^\top G V'$, 其 $-1/2$ 次幂为 $V'^\top (G^\top G)^{-1/2} V'$, 代入即得. Adam 的反例: 取 G 为对角矩阵与其旋转版本, 逐元素 sign-like 归一化给出不同的 R_{spectrum} . $\blacksquare$

4. RLVR 的 covariance 结构

Lemma 4 (score-function 零均值). 对任意参数 θ 和 x , $\mathbb{E}_{y \sim \pi_\theta(\cdot|x)}[\nabla_\theta \log \pi_\theta(y|x)] = 0$. 证明. $\int \pi \nabla \log \pi = \int \nabla \pi = \nabla \int \pi = \nabla 1 = 0$. $\blacksquare$

推论 4.1. 对任意 baseline $b(x)$:

$$G_{\text{RLVR}} = \mathbb{E}_x \left[\text{Cov}_{y \sim \pi} (r(x, y), \nabla_W \log \pi(y|x)) \right].$$

证明. $\mathbb{E}_y[(r - b) \nabla \log \pi] = \mathbb{E}_y[r \nabla \log \pi] - b \cdot 0 = \mathbb{E}_y[r \nabla \log \pi] - \mathbb{E}_y[r] \mathbb{E}_y[\nabla \log \pi] = \text{Cov}_y(r, \nabla \log \pi)$. $\blacksquare$

GRPO 的 $A = (r - \bar{r})/\text{std}$ 是此 covariance 的有限样本估计.

Proposition 5 (谱分量与 frame 分量的 covariance 形式). 定义每条序列的

$$S_i(y) := \frac{\partial \log \pi(y|x)}{\partial \sigma_i} = u_i^\top \nabla_W \log \pi v_i = \sum_t e_{i,t}^0 a_{i,t},$$

$$T_{ij}^U(y) := \frac{\partial \log \pi(y|x)}{\partial (\Theta_U)_{ij}} = \sigma_j (u_i^\top \nabla_W \log \pi v_j) - \sigma_i (u_j^\top \nabla_W \log \pi v_i),$$

其中 $e_{i,t}^0 = u_i^\top \sum_{\tau \geq t} g_t^{(\tau)}$ (不含 credit), Θ_U 是 $U \leftarrow U \exp(\Theta_U)$ 的反对称生成元。则

$$C_{ii} = \mathbb{E}_x \text{Cov}_y(r, S_i), \quad \langle G, \partial W / \partial (\Theta_U)_{ij} \rangle = \mathbb{E}_x \text{Cov}_y(r, T_{ij}^U).$$

证明. $\partial W / \partial \sigma_i = u_i v_i^\top$, 链式法则 $\partial \log \pi / \partial \sigma_i = \langle \nabla_W \log \pi, u_i v_i^\top \rangle = u_i^\top \nabla_W \log \pi v_i$. 对 Θ_U : $dU = U \Theta_U$, $dW = U \Theta_U \Sigma V^\top$; 取 $(\Theta_U)_{ij} = \epsilon$, $(\Theta_U)_{ji} = -\epsilon$, $dW = \epsilon(\sigma_j u_i v_j^\top - \sigma_i u_j v_i^\top)$, 内积即得。两式代入推论 4.1。■

解读. RLVR 谱分量 = reward 与”序列 log-likelihood 对 gain σ_i 的敏感度”的协方差。谱分量小 正确与错误 rollout 对 gain 变化的 likelihood 响应相同。

Proposition 6 (尺度不变约束). 若网络输出对 W 的整体缩放不变, 则对任意 objective $\langle G, W \rangle = \sum_i \sigma_i C_{ii} = 0$. 证明. $f(cW) = f(W) \Rightarrow \frac{d}{dc} \mathcal{L}(cW)|_{c=1} = \langle G, W \rangle = 0$; $\langle G, W \rangle = \text{tr}(V \Sigma U^\top G) = \sum_i \sigma_i (U^\top G V)_{ii}$. ■

所有 objective 共有; 说明谱分量净效应天然被压制, 但不能解释范式差异。Transformer 中对单矩阵仅近似成立, 实验报告 $\langle G, W \rangle / (\|G\| \|W\|)$ 。

Proposition 7 (单步 toy: frame-dominance 不是平凡的). 考虑单步 policy $\pi(y|x) = \text{softmax}(Wx)_y$. 则

$$S_i = a_i(u_{i,y} - \mathbb{E}_\pi[u_{i,\cdot}]), \quad u_i^\top \nabla_W \log \pi v_j = a_j(u_{i,y} - \mathbb{E}_\pi[u_{i,\cdot}]),$$

即对角与非对角项只差标量 a_i vs a_j , 与 reward 的相关系数相同: $\rho_i^\Sigma = \rho_{ij}^{\text{frame}}$. 证明. $\nabla_W \log \pi(y) = (e_y - \pi)x^\top$, $u_i^\top (e_y - \pi) = u_{i,y} - \mathbb{E}_\pi[u_{i,\cdot}]$, $x^\top v_j = a_j$. ■

含义. 单 token 结构不产生 frame-dominance. 若实验观察到 RLVR 的 $|\rho^\Sigma| \ll |\rho^{\text{frame}}|$, 原因只能来自序列级效应或 pretrained 权重的结构, 这正是下面假设的内容。【判定: 实验观察到的是对称而非 $|\rho^\Sigma| \ll |\rho^{\text{frame}}|$ (见 H-RLVR 判定)——本命题的对称性在真实序列模型上成立, 从 toy 引理升级为正结果】

Hypothesis H-RLVR (gain-sensitivity 的 reward 无关性). 对 on-policy 采样的 pretrained model, $S_i(y) = \sum_t e_{i,t}^0 a_{i,t}$ 主要由 reward 无关因素决定: 1. 温度效应: 放大 σ_i 近似均匀缩放该 mode 贡献的 logits, 主要改熵; 组内归一化后熵与 A 相关弱。2. 长度效应: S_i 随长度累加, 长度归一化削弱其与 A 的相关。3. 使用对称性: 已有 mode 被正确与错误 rollout 以相近频率使用 (它是 pretrained 能力, 不是本次新学的); 序列级求和使 $\sum_t e_{i,t}^0 a_{i,t}$ 的符号交替项相互抵消。

而 T_{ij} 编码”在此 prompt 上把 v_j 路由到 u_i ”, 是区分正误轨迹的信息。

可证伪量.

$$\rho_i^\Sigma := \text{Corr}_y(A, S_i), \quad \rho_{ij}^{\text{frame}} := \text{Corr}_y(A, T_{ij}).$$

预测: RLVR 下 $|\rho^\Sigma|$ 集中于 0, $|\rho^{\text{frame}}|$ 有尾; OPD 下 $|\rho^\Sigma|$ 显著更大。对照: 对 pretrained 能力之外的 mode (新增随机 LoRA 方向), $|\rho^\Sigma|$ 应上升 (检验第 3 点)。

若实验支持, 可在简化模型 (线性 policy + 高斯 reward + 长序列) 下尝试证明 $\rho^\Sigma \rightarrow 0$ 的集中不等式。

【判定 H-RLVR 被拒绝 (0.8B RLVR, GSM8K)。K=8 初测: $|\hat{\Sigma}|$ 中位 0.291 $|\hat{\text{frame}}|$ 0.292, 零假设 0.278; 加强采样终判 (P=4、K=16、每保存步 4 个完整组, 统计力 8 $\times$): 0.1314 vs 0.1308, 匹配零假设 0.1305——与 frame 完全对称, 各自仅约 1.6 个百分点的真实相关尾部且两方向均匀。“ $|\hat{\Sigma}|$ 集中于 0”的预测成立, 但破缺不存在; Prop.7 的单步对称性由此升级为实验验证的性质。简化模型的证明目标相应改为”对称性定理”而非”集中不等式”。】

5. SNR 理论: 幅值混合了信号与尺度

设定. 一个 prompt, K 条 rollout, $\hat{G} = \frac{1}{K} \sum_k A_k \nabla \log \pi(y_k)$. 对任一 mode 统计量 $s(y)$ (S_i 或 T_{ij}), $\hat{C}_s = \frac{1}{K} \sum_k A_k s_k$. 记 $\mu_s = \text{Cov}(A, s)$, $\rho_s = \text{Corr}(A, s)$, $\sigma_s^2 = \text{Var}(s)$, 组内归一化下 $\sigma_A \approx 1$, $\mathbb{E}[A] = 0$.

Lemma 8. $\mathbb{E}[s] = 0$. 证明. s 是 $\log \pi$ 对某参数化方向的导数, 由 Lemma 4 期望为零。■

Proposition 9 (GRPO 估计量的信号与噪声).

$$\mathbb{E}[\hat{C}_s] = \mu_s = \rho_s \sigma_s, \quad \text{Var}[\hat{C}_s] = \frac{1}{K} \text{Var}(As).$$

若 (A, s) 联合高斯, 则 $\text{Var}(As) = \sigma_s^2(1 + \rho_s^2)$, 从而

$$\text{SNR}_s := \frac{\mu_s^2}{\text{Var}[\hat{C}_s]} = \frac{K\rho_s^2}{1 + \rho_s^2}.$$

证明. $\mathbb{E}[As] = \text{Cov}(A, s) + \mathbb{E}[A]\mathbb{E}[s] = \mu_s$ i.i.d. 平均给方差。联合高斯、均零: $\mathbb{E}[A^2s^2] = \sigma_A^2\sigma_s^2 + 2\text{Cov}(A, s)^2 = \sigma_s^2(1 + 2\rho_s^2)$ (Isserlis), $\text{Var}(As) = \sigma_s^2(1 + 2\rho_s^2) - \rho_s^2\sigma_s^2 = \sigma_s^2(1 + \rho_s^2)$. ■

Proposition 10 (幅值 信号) . 观测幅值

$$|\hat{C}_s| \approx |\rho_s|\sigma_s + O\left(\sigma_s\sqrt{\frac{1+\rho_s^2}{K}}\right),$$

同时依赖 ρ_s (signal) 与 σ_s (与 signal 无关的尺度); SNR 只依赖 ρ_s 。

证明. 由 Prop.9 的均值与标准差。■

推论 **10.1** (Muon / Pion 的退化机制) . Muon 与 Pion 的选择变量都是幅值 $\approx |\rho|\sigma_s$, 在 σ_s 异质时系统性偏向高方差 mode。Pion 报告的”RLVR 下 Muon 放大 tail noise” 的精确机制: 不是 tail 本身是噪声, 而是 tail 中 σ_s 大而 ρ_s 小的 mode 被幅值判据误选。

推论 **10.2** (密度效应) . 稠密监督 (SFT / OPD) 每位置有独立 credit。若各位置信号对齐、噪声独立, mode 统计量的信号 $\propto T$, 噪声 $\propto \sqrt{T}$, 有效 SNR 比 RLVR 高 $O(T)$ 。这是”Muon 在 pretraining 有效、RLVR 退化”的定量解释; 可通过在 RLVR 中加密 credit (process reward) 验证 SNR 随之上升。

与 Adam 的关系. Adam 的 $m/\sqrt{v}$ 是逐坐标 SNR 归一化 (m^2/v); Muon 在谱基下做幅值归一化不看 SNR。本文方法 M1 = 谱基下的 SNR 归一化。

6. Part I 实验协议

6.1 Setup (固定)

- Base: Qwen3-1.7B 或 Llama-3.2-3B, 验证后上 7-8B。
- Prompt 集: 数学 (GSM8K / MATH 子集), 三范式共用。SFT: prompt+ 标准解; OPD: student rollout + 同 family 大模型 reverse KL; RLVR: GRPO, correctness reward, $K = 8$ 。
- 同 token budget, AdamW 为主, Muon 对 SFT / RLVR 各跑一遍。几百步。
- 每 10 步存 G_t, H_t, W_t , 约 16 个矩阵 (早/中/晚层 $\times$ Q/K/V/O/gate/up/down 抽样)。
- 每保存 step 额外 $B = 8$ 组 minibatch / rollout 组算 $G^{(b)}$ 。

6.2 指标

几何 (对 G_t 与 H_t 各算): R_{spectrum} ; G 能量在 W 的 top/mid/tail 子空间占比; G 的 top 奇异向量与 W 子空间的 principal angles; G 的 stable rank; 累积量 $\|\sigma(W_t) - \sigma(W_0)\|$ 、子空间旋转 (sanity)。

统计: $\widehat{\text{SNR}}_{ij} = \bar{C}_{ij}^2 / \widehat{\text{Var}}_b(C_{ij}^{(b)})$; RLVR 下直接估 $\rho_i^\Sigma, \rho_{ij}^{\text{frame}}$ (每条 rollout 单独反传, 只对少数矩阵)。

功能 (MLP): NaNA 的 SCA 贡献 c_i , held-out 集聚合 $|c_i|$ 均值; RLVR 用高 advantage 位置。把 mode 分 high-/low-contribution 两桶, 看 G 能量落在哪桶。

6.3 假设与预测

假设	定量预测	检验
H1 谱倾向由 credit 密度决定	$R_{\text{spectrum}}(\bar{G})$: SFT > OPD > RLVR	Phase 1 主图
H2 optimizer 只调制	AdamW/Muon 不改 H1 的 ordering; Muon 下 R_{spectrum} 只依赖 $\text{polar}(C)$ (Prop.3)	G vs H

假设	定量预测	检验
H3 RLVR 谱分量 reward 无关	ρ^Σ 集中于 0, ρ^{frame} 有尾; OPD 的 ρ^Σ 更大	§4 直接估计
H4 幅值混合 ρ 与 σ_s	RLVR 中 $ \bar{C}_{ij} $ 与 $\widehat{\text{SNR}}_{ij}$ 秩相关低; SFT 高	§6.2
H5 spectrum-only 无法建新关联	RLVR: spectrum-only 失败、frame-only full; SFT 相反	Phase 2
H6 SNR 选择优于幅值	同稀疏度 SNR-top- q > Mag-top- q , 差距 RLVR 最大	Phase 2
H7 高贡献 mode 谱变化致遗忘	限制 high- c 的 $\dot{\sigma}$ 减少遗忘不损任务	Phase 2 + held-out

【逐条判定 2026-09-08】 - **H1** : 排序 SFT>OPD>RLVR 成立 (0.8B 归一化富集 0.886>0.869>0.839, 27 矩阵 $\times$ 50 步一致; Llama-3B 在未饱和窗口 1.084>1.060 复现)。理论期待的悬殊对比未出现——总跨度仅约 5%, 且三范式绝对值均处随机基线附近。幅度叙事需弱化, 谱-frame 差异的主要载体是 SNR 结构而非对角能量占比。 - **H2** : 三对全部成立, G 侧差异 <7%。附加发现: Muon 的 H 谱富集在 RLVR 下消失。 - **H3** : 见 §4 判定, H-RLVR 拒绝。 - **H4** : 秩相关排序两架构一致, 但 RLVR 端绝对值仍高 (0.848/0.785), 强形式未现; 归 H6 干预裁决。 - **H5/H6** : Phase 2 在途 (作者 B)。 **H7**: 已按 **14** 天砍单剪除, 不检验。 - 家族轴: H4 排序在标准注意力 (Llama) 上完整复现且差距更大; H1 排序在活跃 RLVR 阶段复现。尺度轴 4B/9B 在途。

6.4 干预协议 (Phase 2)

训练循环中把 H_t 替换为投影:

约束	投影
Spectrum-only	$P_\Sigma(H) = U \text{diag}(U^\top H V) V^\top$
Frame-only	$H - P_\Sigma(H)$, 或按 Prop.1 做严格 isospectral 更新
High- c only / Low- c only	按 SCA 桶取行列块
SNR-top- q / Mag-top- q	只保留 $\widehat{\text{SNR}}$ 或 $ \bar{C} $ 前 $q\%$ 项

Part II —优化方法

每个方法绑定 Part I 的触发条件; 条件不成立则方法不进 paper。

M1. Spectral-SNR Descent (SSD)

触发: H4 + H6。【H4 弱形式成立; H6 在途。SSD 已实现并通过 GPU 试跑 (RLVR 50 步, reward 正常爬升, 开销 +15%), E1/E2 在途】规则: 梯度奇异基下 SNR 加权。

$$\bar{G} = P \Lambda Q^\top, \quad H = P \text{diag}(f(\widehat{\text{SNR}}_\ell)) Q^\top$$

$$m_\ell \leftarrow \beta_1 m_\ell + (1 - \beta_1) p_\ell^\top G_t q_\ell, \quad v_\ell \leftarrow \beta_2 v_\ell + (1 - \beta_2) (p_\ell^\top G_t q_\ell)^2, \quad \widehat{\text{SNR}}_\ell = m_\ell^2 / v_\ell$$

$f(s) = s/(1+s)$ (Wiener 系数, 高斯下 MSE 最优) 或硬阈值。 $f \equiv 1$ 退化为 Muon。基漂移: 用上一步 (P, Q) warm start 做 Newton-Schulz, Hungarian 匹配对齐 mode 后更新 EMA; 只对 top- k 维护, 尾部统一收缩。对比: AdamW、Muon、Pion。预期: RLVR 上不出现 Muon 退化; 增益与 Part I 测得的 ρ, σ_s 异质性成正比 (按 layer 散点)。SFT 上与 Muon 持平。开销: 与 Muon 同量级 + $2k$ 标量 EMA / 矩阵。

M2. Adaptive Spectrum-Frame Learning Rates

触发: H1 + H5。【H1 方向成立; H5 在途。M2 已实现 (adaptive_alpha 干预模式), E4 在途】规则:

$$C = U^\top H V, \quad H' = U(\alpha_t \text{diag } C + \beta_t (C - \text{diag } C)) V^\top, \quad \alpha_t = g\left(\frac{1}{r} \sum_i \widehat{\text{SNR}}_{ii}\right), \quad \beta_t = 1$$

只有 gradient 持续给出可靠 gain 信号才允许改谱。ISO 是 $\alpha \equiv 0$ ，普通训练 $\alpha \equiv 1$ 。按 (layer, type) 独立维护。对比：ISO、AdamW/Muon。三范式同一套规则。预期：不劣于各自最优固定选择 (RLVR ISO, SFT full)，RLVR 上遗忘低于 full。开销：每 N 步刷新权重 SVD，中间用 Prop.1 一阶传播。

M3. Contribution-Aware Spectral Regularizer

触发：H7。【H7 已按 14 天实验预算剪除——本方法留作 future work，不进主文】规则：SCA 贡献 c_i ， $\lambda_i \propto |c_i|$ ，

$$\mathcal{R}(W) = \sum_i \lambda_i (\sigma_i(W) - \sigma_i(W_0))^2$$

或 update 层面 $C_{ii} \leftarrow C_{ii}/(1 + \lambda_i)$ 。只惩罚谱变化不惩罚 frame——允许新关联，禁止改写已有关联强度。对比：KL-to-base、weight decay toward W_0 、EWC。预期：同 forgetting 下任务更高，SFT 上最明显。限制：SCA 只对 MLP 有定义。

M4. Layer-Wise Optimizer Routing

触发：Part I 发现 layer type 异质性大于 objective 差异。规则：每矩阵监测对角 SNR 均值与 mode SNR 离散度，四象限选 AdamW/Muon、SSD、ISO-like、SSD+ $\alpha \rightarrow 0$ 。是 controller 不是新 optimizer。

M5. Subspace-Locked Optimizer States

触发：gradient 高 SNR 子空间早期锁定。规则：前 T_0 步全量；之后固定 rank- k 子空间，只在 $P_k^\top G_t Q_k$ 上维护 Adam 状态， $O(k^2)$ 而非 $O(mn)$ ；每 N 步用 SNR 检查覆盖。与 GaLore 区别：按 SNR 而非幅值选。

M6. SNR-Guided Credit Densification

触发：推论 10.2。规则： $c_\tau = A + \gamma_t w_\tau^{\text{OPD}}$ ， γ_t 由 mode SNR 均值控制——SNR 低时多用 teacher，高时退回纯 RLVR。

M7. SNR-Aware Rank Allocation for LoRA

触发：update spectrally concentrated 且高 SNR mode 数按层差异大。规则： $r_\ell = \#\{\widehat{\text{SNR}}_\ell > \tau\}$ ，总预算固定按层重分配；LoRA 初始化到高 SNR 子空间。

推荐配置

一篇 paper：Part I 完整 + M1 + M2，M3 附加。M4-M7 视 Part I 结果，留 future work 或第二篇。

每个方法过三关：(1) 消融——去掉 SNR / 谱分解退回 baseline；(2) 预测——Part I 测得的量能预测方法在哪些设置增益大；(3) 跨范式——RLVR 有效且 SFT 不劣。第 (2) 关是与“又一个 optimizer”的区别。

6b. Part II 理论

6b.1 M1 的最优性

设定。固定谱基 (P, Q) (假设在一步内稳定)，真实梯度在该基下的 mode 系数 μ_ℓ ，观测 $\hat{c}_\ell = \mu_\ell + \varepsilon_\ell$ ， $\varepsilon_\ell \sim \mathcal{N}(0, \tau_\ell^2)$ 独立；先验 $\mu_\ell \sim \mathcal{N}(0, s_\ell^2)$ 。定义 $\text{SNR}_\ell := s_\ell^2/\tau_\ell^2$ 。update $H = \sum_\ell h_\ell p_\ell q_\ell^\top$ ， $h = h(\hat{c})$ 可测。一阶 loss 下降为 $\langle G^*, H \rangle = \sum_\ell \mu_\ell h_\ell$ 。

Lemma 11 (Wiener 收缩)。 $\mathbb{E}[\mu_\ell | \hat{c}_\ell] = \frac{\text{SNR}_\ell}{1 + \text{SNR}_\ell} \hat{c}_\ell = f(\text{SNR}_\ell) \hat{c}_\ell$ 。证明。高斯先验 + 高斯噪声的后验均值： $\mathbb{E}[\mu | \hat{c}] = \frac{s^2}{s^2 + \tau^2} \hat{c}$ 。 ■

Proposition 12 (SSD-Wiener 是范数预算下的 Bayes 最优 update)。在约束 $\mathbb{E}\|h\|^2 = 1$ 下，

$$\max_h \mathbb{E} \left[\sum_\ell \mu_\ell h_\ell \right]$$

的解为 $h_\ell^* \propto f(\text{SNR}_\ell) \hat{c}_\ell$ ，最优值为 $\sqrt{\mathbb{E}\|f(\text{SNR}) \odot \hat{c}\|^2} = \sqrt{\sum_\ell s_\ell^2 f(\text{SNR}_\ell)}$ 。

证明. 塔性质: $\mathbb{E}[\sum_{\ell} \mu_{\ell} h_{\ell}] = \mathbb{E}[\sum_{\ell} \mathbb{E}[\mu_{\ell} | \hat{c}] h_{\ell}] = \mathbb{E}[\langle m, h \rangle]$, $m_{\ell} := f(\text{SNR}_{\ell}) \hat{c}_{\ell}$. Cauchy-Schwarz: $\mathbb{E}[\langle m, h \rangle] \leq \sqrt{\mathbb{E}\|m\|^2} \sqrt{\mathbb{E}\|h\|^2} = \sqrt{\mathbb{E}\|m\|^2}$, 等号当且仅当 $h \propto m$. $\mathbb{E}[m_{\ell}^2] = f^2 \mathbb{E}[\hat{c}_{\ell}^2] = f^2(s_{\ell}^2 + \tau_{\ell}^2) = s_{\ell}^2 f(\text{SNR}_{\ell})$. ■

推论 12.1 (Muon 的损失). Muon 取 $h_{\ell} = \text{sign}(\hat{c}_{\ell})/\sqrt{r}$ (每 mode 单位增益). 设 r_0 个 mode 为纯噪声 ($s_{\ell} = 0$), $r_1 = r - r_0$ 个 mode 同 $\text{SNR} = \kappa$ 、同 s . 则

$$\frac{\mathbb{E}\langle G^*, H_{\text{Muon}} \rangle}{\mathbb{E}\langle G^*, H^* \rangle} = \sqrt{\frac{r_1}{r}} \cdot \frac{\mathbb{E}[\mu \text{sign}(\hat{c})]}{s\sqrt{f(\kappa)}} = \sqrt{\frac{r_1}{r}} \cdot \sqrt{\frac{2}{\pi}} \cdot \sqrt{\frac{\kappa}{1+\kappa}} / \sqrt{\frac{\kappa}{1+\kappa}} = \sqrt{\frac{2r_1}{\pi r}}.$$

证明. 噪声 mode 上 $\mathbb{E}[\mu \text{sign}(\hat{c})] = 0$, Muon 把 r_0/r 的范数预算浪费在那里. 信号 mode 上 $(\mu, \hat{c})$ 联合高斯, $\text{Corr} = \sqrt{\kappa/(1+\kappa)}$, $\mathbb{E}[\mu \text{sign}(\hat{c})] = s\sqrt{2/\pi} \sqrt{\kappa/(1+\kappa)}$. 代入 Prop.12 的最优值. ■

解读. Muon 相对最优的效率是 $\sqrt{2r_1/\pi r}$: 即使无噪声 mode ($r_1 = r$) 也只有 $\sqrt{2/\pi} \approx 0.80$ (sign 相对线性收缩的固有损失); 噪声 mode 占比越高损失越大. 这与 Part I 的 H4 (RLVR 中大量 mode $\rho \approx 0$) 直接对接: r_0/r 就是 Phase 1 可测的量, E3 预测关的横轴即由此而来.

SSD 的两个变体. - **SSD-Wiener**: $h_{\ell} = f(\text{SNR}_{\ell}) \hat{c}_{\ell}$, Prop.12 的最优解. - **SSD-Muon**: $h_{\ell} = f(\text{SNR}_{\ell}) \text{sign}(\hat{c}_{\ell})$, 保留 Muon 的谱平坦化但按 SNR 门控. 由推论 12.1 的计算, 其效率为 $\sqrt{2/\pi} \cdot \sqrt{\sum_{\ell} s_{\ell}^2 f / \sum_{\ell} s_{\ell}^2}$ 量级, 在噪声 mode 上不浪费预算. 两者都在 E2 消融中对比.

6b.2 M2 的谱漂移控制

Proposition 13. 令 $H' = U(\alpha \text{diag } C + \beta \text{off}(C))V^{\top}$, $C = U^{\top} H V$. 则 1. $\dot{\sigma}_i = \alpha C_{ii}$, 故 $\|\sigma(W_{t+1}) - \sigma(W_t)\| \leq \alpha_t \|\text{diag } C_t\| + O(\|H\|^2)$, 累积谱漂移 $\leq \sum_t \alpha_t \|\text{diag } C_t\|$. 2. 若 $H = -\eta G$, 一阶 loss 变化为 $-\eta(\alpha \|\text{diag } C\|^2 + \beta \|\text{off}(C)\|^2) \leq 0$, 任意 $\alpha, \beta \geq 0$ 都是下降方向. 3. $\alpha = 0$ 时更新一阶等谱, 恢复 ISO; $\alpha = \beta = 1$ 恢复原 update.

证明. (1) Prop.1 应用于 H' : $U^{\top} H' V$ 的对角为 αC_{ii} . (2) $\langle G, H' \rangle = \langle C, \alpha \text{diag } C + \beta \text{off}(C) \rangle$ (Frobenius 内积在正交变换下不变), 对角与非对角正交. (3) 直接. ■

推论 13.1 (SNR 门控的意义). 取 $\alpha_t = g(\text{SNR}_t^{\text{diag}})$, $g(0) = 0$ 、单调. 由 Lemma 11, 对角 mode 的 Bayes 后验均值 $\propto f(\text{SNR}_{ii}) C_{ii}$; 当对角 SNR 均为零时后验均值为零, 此时 $\alpha = 0$ 是 Prop.12 意义下的最优选择, M2 与 SSD 在对角块上一致. M2 是 SSD 在“对角 vs 非对角”这个二分粒度上的粗化, 代价是每步权重 SVD, 好处是不需要 mode 级对齐.

6b.3 M3 的遗忘界

Proposition 14. 对 held-out 输入 x 、目标 t^* , NaNA 的 DEU 贡献 $c_i(x) = (\sigma_i v_i^{\top} x)(t^{*\top} u_i)$, 目标 $\text{logit} = \sum_i c_i(x)$. 在 spectrum-only 变化 $\Delta\sigma$ 下,

$$\Delta \text{logit}(x) = \sum_i \frac{\Delta \sigma_i}{\sigma_i} c_i(x), \quad |\Delta \text{logit}(x)| \leq \left(\sum_i \lambda_i \Delta \sigma_i^2 \right)^{1/2} \left(\sum_i \frac{c_i(x)^2}{\lambda_i \sigma_i^2} \right)^{1/2}.$$

取 $\lambda_i = \bar{c}_i / \sigma_i^2$ ($\bar{c}_i$ 为 held-out 集上 $|c_i|$ 的均值), 第二因子在 held-out 分布上的期望被 $\sum_i \bar{c}_i$ 控制, 与训练无关. 因此 M3 的正则项 $\mathcal{R} = \sum_i \lambda_i \Delta \sigma_i^2$ 直接界住 held-out logit 的谱漂移部分.

证明. 由 Prop.2, $\Delta(Wx) = \sum_i \Delta \sigma_i (v_i^{\top} x) u_i$, 与 t^* 内积得 $\sum_i \Delta \sigma_i (v_i^{\top} x)(t^{*\top} u_i) = \sum_i (\Delta \sigma_i / \sigma_i) c_i$. 不等式为 Cauchy-Schwarz. ■

解读. M3 只约束 $\Delta\sigma$, frame 变化对 held-out logit 的影响不受约束——这是设计选择: 由 Prop.2, 新关联只能通过 frame 建立, M3 保留了这条通道. KL-to-base 和 L2 同时约束两者, 因此在“加能力不毁能力”上 M3 的 Pareto 前沿应更靠外 (E6 检验). 反过来, 若 Phase 1 发现 held-out 能力损失主要来自 frame 而非谱 (H7 不成立), M3 的界虽然成立但无用, 方法不进 paper.

7.1 通用设置

- 模型、prompt 集、budget 与 §6.1 相同, 保证 Part I 的测量可直接用于预测。
- 评测:
 - 任务: GSM8K / MATH500 pass@1 (RLVR、OPD、SFT 各自的目标任务)。
 - 遗忘: MMLU、HumanEval、IFEval 相对 base 的变化, 作为 held-out 能力。

- 训练动态: reward / loss 曲线、每步 $R_{\text{spectrum}}(H_t)$ 、 $\|\sigma(W_t) - \sigma(W_0)\|$ 。
- 每个配置 3 seeds, 报告均值 $\pm$ std。
- 超参: 每个 optimizer 在 SFT 上 sweep lr 一次, 其它范式沿用 (避免”调参优势”)。

7.2 实验清单

E1: SSD vs baselines (M1 主实验) - 配置: $\{\text{AdamW}, \text{Muon}, \text{Pion}, \text{SSD}\} \times \{\text{SFT}, \text{OPD}, \text{RLVR}\}$, 12 组。- 输出: 任务性能表; RLVR 训练曲线 (重点看 Muon 是否退化、SSD 是否不退化)。- 通过标准: RLVR 上 SSD AdamW 且 $>$ Muon; SFT / OPD 上 SSD Muon。

E2: SSD 消融 - $f \equiv 1$ (退化为 Muon)、硬阈值 vs Wiener、只对 top- k 维护 SNR 的 $k \in \{64, 256, \text{full}\}$ 、EMA 系数、是否做 mode 对齐。- 通过标准: 去掉 SNR 加权后性能回落到 Muon 水平; mode 对齐去掉后明显退化。

E3: 预测关 (Part I $\rightarrow$ M1) - 对每个 layer, 用 Phase 1 测得的 mode-wise (ρ_s, σ_s) 异质性 (例如 $|\bar{C}|$ 与 $\widehat{\text{SNR}}$ 的秩相关的 1- 值) 作横轴, SSD 相对 Muon 在该层单独启用时的增益作纵轴, 画散点。- 通过标准: 正相关显著。这是 paper 区别于”又一个 optimizer”的关键图。

E4: Adaptive spectrum-frame (M2 主实验) - 配置: $\{\text{full}, \text{ISO} (\alpha = 0), \text{M2 自适应} \alpha_t\} \times \{\text{SFT}, \text{OPD}, \text{RLVR}\}$, AdamW 底座。- 输出: 任务性能 + 遗忘指标双轴; α_t 随 step 和 layer 的轨迹图 (预期 RLVR 上 $\alpha_t \rightarrow 0$, SFT 上保持高)。- 通过标准: M2 在三范式上都不劣于各自的最优固定选择; RLVR 上遗忘低于 full。

E5: M2 的 layer 分解 - 只在 attention 或只在 FFN 上启用自适应 α , 其余用 full。- 输出: 哪类 layer 贡献了 M2 的主要增益, 与 Part I 的 layer 异质性对照。

E6: Contribution-aware regularizer (M3, 附加) - 配置: $\{\text{无正则}, \text{KL-to-base}, \text{L2-to-}W_0, \text{M3}\}$, SFT 与 RLVR。- 输出: 任务性能 vs 遗忘的 Pareto 曲线 (扫 λ 强度)。- 通过标准: M3 的 Pareto 前沿在 KL / L2 之外。

E7: SSD 在 Muon 已知强项上的 sanity - 小规模 continued pretraining (几千步), SSD vs Muon。- 通过标准: 不劣于 Muon。防止审稿人质疑 SSD 只是在 RLVR 上”修”了 Muon 而牺牲了 pretraining。


7.3 全文图表清单

编号	内容	来源
Fig.1	概念图: credit 密度连续谱 + spectral/frame 分解	§2
Fig.2	$R_{\text{spectrum}}(G_t)$ 三范式随 step, 按 layer type 分面	Phase 1, H1
Fig.3	$R_{\text{spectrum}}(G)$ vs $R_{\text{spectrum}}(H)$, AdamW / Muon	Phase 1, H2
Fig.4	ρ^Σ 与 ρ^{frame} 的分布, RLVR vs OPD	Phase 1, H3
Fig.5	$ \bar{C}_{ij} $ vs $\widehat{\text{SNR}}_{ij}$ 散点, 三范式	Phase 1, H4
Fig.6	干预实验: spectrum-only / frame-only 下三范式性能	Phase 2, H5
Fig.7	SNR-top- q vs Mag-top- q 性能随 q	Phase 2, H6
Tab.1	E1 主表: 4 optimizer $\times$ 3 范式	E1
Fig.8	RLVR 训练曲线: Muon 退化 vs SSD	E1
Fig.9	预测关散点	E3
Fig.10	α_t 轨迹 + 性能 / 遗忘双轴	E4
Tab.2	消融	E2, E5
Fig.11	M3 Pareto (附录或正文)	E6

7.4 算力估计 (3B 模型)

- Phase 1: 3 范式 $\times$ ~ 500 步 + 8 组 SNR 反传 主训练的 3-4 倍开销, 单节点 $8 \times \text{A100}$ 约 3-4 天。
- Phase 2: 6 种约束 $\times$ 3 范式 $\times$ 3 seeds 54 runs, 每 run 短 (几百步), 约 1 周。
- E1-E7: 约 60 runs, 含 seeds, 约 1.5-2 周。
- 7-8B 复现: 只跑 E1 与 Fig.2/4, 约 1 周。

7.5 依赖关系



Phase 1 的数据在 E3 里被第二次使用：这是分析与方法之间的硬链接。

Part III —执行

时间线

阶段	内容	周
Phase 1	三范式跑完，出 R_{spectrum} 、 G vs H 、SNR 三张主图；估 $\rho^\Sigma, \rho^{\text{frame}}$	2-3
决策点	H1 成立 → Phase 2；不成立 → 主线改为 optimizer 效应 (H2) + §5	—
Phase 2	干预实验，检验 H5-H7	2
Phase 3	M1、M2 实现与对比	2-3
理论	与 Phase 1 并行：H-RLVR 在简化模型下的证明尝试	—

工程

- SVD: randomized top-256 + tail 块；或只在保存 step 离线算。
- Mode 跨 step 对齐: principal angle / Hungarian, 不按 index。
- SNR 估计: RLVR 至少 8 组 rollout, 主要算力开销。
- SVD 符号歧义对 $u_i^\top G v_i$ 无影响；功能标签两方向都看。

待定

1. Base model 与算力 (1.7B 还是 3B 起)。
2. OPD teacher 来源。
3. 是否做 Phase 3 / M1-M2, 决定 venue 与时间线。

附：理论的诚实边界

- 已证 (**Part I**): Prop.1、2、3、6、7, Lemma 4、8, 推论 4.1, Prop.9、10。
- 已证 (**Part II**): Lemma 11 (Wiener 收缩)、Prop.12 (SSD-Wiener 的 Bayes 最优性)、推论 12.1 (Muon 效率 $\sqrt{2r_1/\pi r}$)、Prop.13 (M2 谱漂移界与下降性)、Prop.14 (M3 遗忘界)。Part II 的证明依赖”谱基在一步内稳定 + 高斯先验”两个假设，前者由 E2 的 mode 对齐消融检验。
- 假设: H-RLVR。【H-RLVR 已被证伪，见 §4 判定;Prop.7 对称性转为正结果】§4 给出其精确 covariance 形式与可证伪量；Prop.7 说明它不是平凡的。若 Phase 1 支持，尝试在简化模型下证明。
- 近似: Prop.9 的闭式依赖联合高斯；不依赖近似的是 $\mu_s = \rho_s \sigma_s$ 与 $\text{SNR} \propto K \rho_s^2$ 。Prop.6 在 Transformer 中对单矩阵近似成立。
- 独立性: 即使 H1/H3 被证伪，§5 SNR 理论 + M1 仍构成一篇完整 paper。【该预案已正式启用 (2026-09-08):H3 证伪、H1 仅方向成立, 主线 = §5 SNR 理论 + M1 + H5/H6 因果干预 + H2】